In [ ]:
```python
import numpy
import pandas
import matplotlib.pyplot as plt
```

单变量线性回归

即拟合一个形如y=ax+b的一个方程，拟合的参数就是a、b
这里我们令a=theta1,b=theta0。
用数学表达就是y=[1,x]@[theta0,theta1].T
基于矩阵乘的优势，我们可以把批量的x带入方程中，求出y

方法

根据梯度下降的原理，我们初始化一个theta1,theta2（这里我设的是0，0）
然后需要计算初始化的方程与期望的结果之间的差距，即为代价函数cost()。对于此处，我们可以定义代价函数为所有的计算结果与实际结果的平方，然后除以两倍的样本数量，公式如下

$$J(\theta)=\frac{1}{2m}\sum_{i=1}^{m}\left(h_\theta\left(x^{(i)}\right)-y^{(i)}\right)^2$$

得到代价函数后，我们可以知道，若想使直线尽可能的拟合散点集，就需要尽可能的减小代价函数，我们使用的方法就是梯度下降
其原理就是对需要调整的theta值求偏导，偏导数反应了该theta值对整体的上升和下降的情况，若偏导大于0，说明此时对整体的误差有拉高作用，
此时较底点在右边，需要减小一个量，因为偏导数约大，说明上升的趋势约明显，所以减小的量可以和偏导数的值成正比。偏导数小于0也是同理。 以此我们就可以构建出逐步逼近代价函数最小值得地方，下降公式如下

$$\theta_j:=\theta_j-\alpha\frac{\partial}{\partial\theta_j}J(\theta)$$

代码实现

getData()方法

用于获取初式的基本数据，以及对数据进行加工，这里获取了ex1data1.txt中的数据，主要为x和y的值，初始化了tehta0和theta1默认为0
在x中加入了一列1，便于之后整体的矩阵求结果

In [ ]:
```python
def getData():
    data=numpy.array(pandas.read_csv('ex1data1.txt'))
    data=numpy.insert(data,0,numpy.ones((data.shape[0])),axis=1)
    theta=numpy.array([0,0])
    return data,theta
```

compute()方法

用于计算给定的theta和y来求此时的输出y,便于之后求下降后改变theta后的代价

In [ ]:
```
def compute(data,theta):
    return data[:,:2]@theta
```

cost()方法

用于计算不同tehta时的代价变化情况，同时返回各样本的误差供下降的时候使用

In [ ]:
```
def cost(data,theta):
    yo=compute(data,theta)
    errorValue=yo-data[:,2]
    return numpy.power(errorValue,2).sum()/(2*data.shape[0]),errorValue
```

gradient()方法

即梯度下降的核心方法，用于计算当前theta下，误差对各theta的偏导数情况

In [ ]:
```
def gradient(data,errorValue):
    decline=(errorValue.reshape(1,-1).T*data[:,0:2])
    return numpy.sum(decline,axis=0)/(data.shape[0])
```

main()主方法

调用上述函数，完成一次完整的梯度下降，调节迭代次数与下降速度观察代价的变化情况
程序整体流程是 读取所需数据——》计算代价并保存——》下降theta并更新theta——》得到新的tehta后继续第二步（计算代价并保存） 之后的代码就是绘制代价函数图相和散点拟合情况图

In [ ]:
```
def main(gen,speed):

    data,theta=getData()
    costs=[]
    for i in range(gen):
        j,errorValue=cost(data,theta)
        theta=theta-speed*gradient(data,errorValue)
        costs.append(j)
    plt.plot(costs)
    plt.show()
    plt.scatter(data[:,1],data[:,2])
    print(theta)
    x=numpy.arange(4,30,0.01)
    y=x*theta[1]+theta[0]
    plt.scatter(x,y,s=0.1)
    print("代价最小为：",min(costs))
```

改变参数，观察结果并分析

迭代次数10，下降速度0.001

In [ ]:
```
main(10,0.001)
```

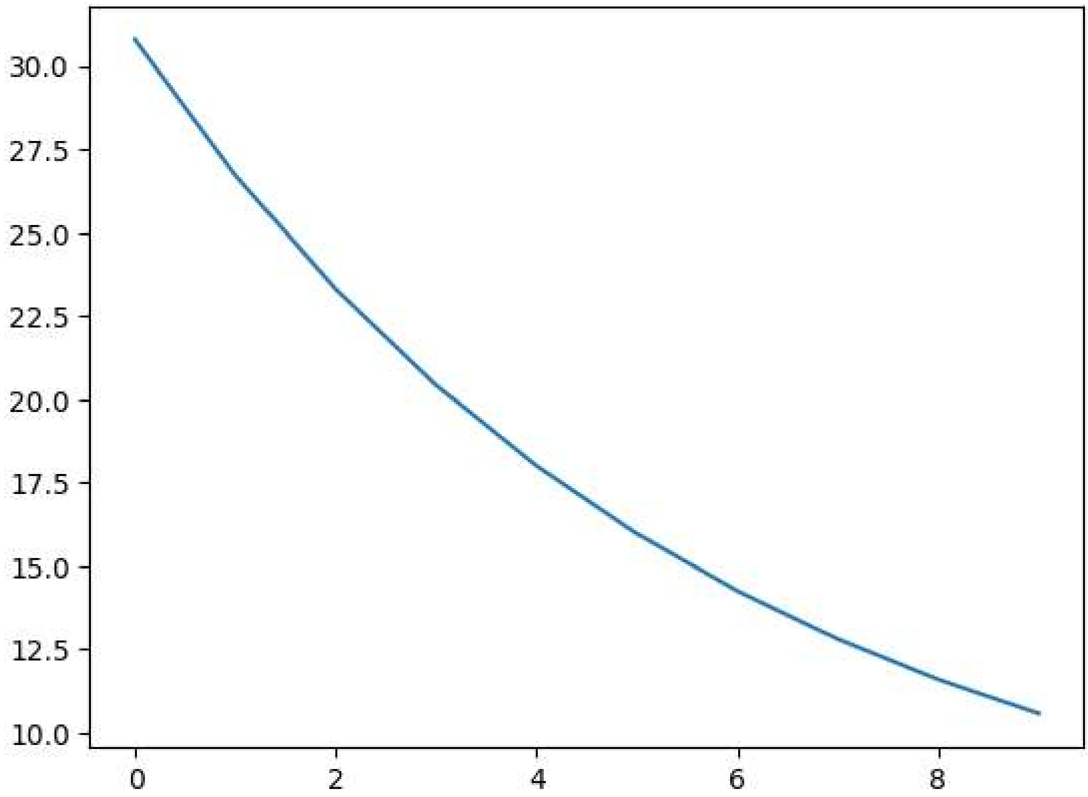

```
[0.03764683 0.45393872]
代价最小为： 10.559618437644504
```

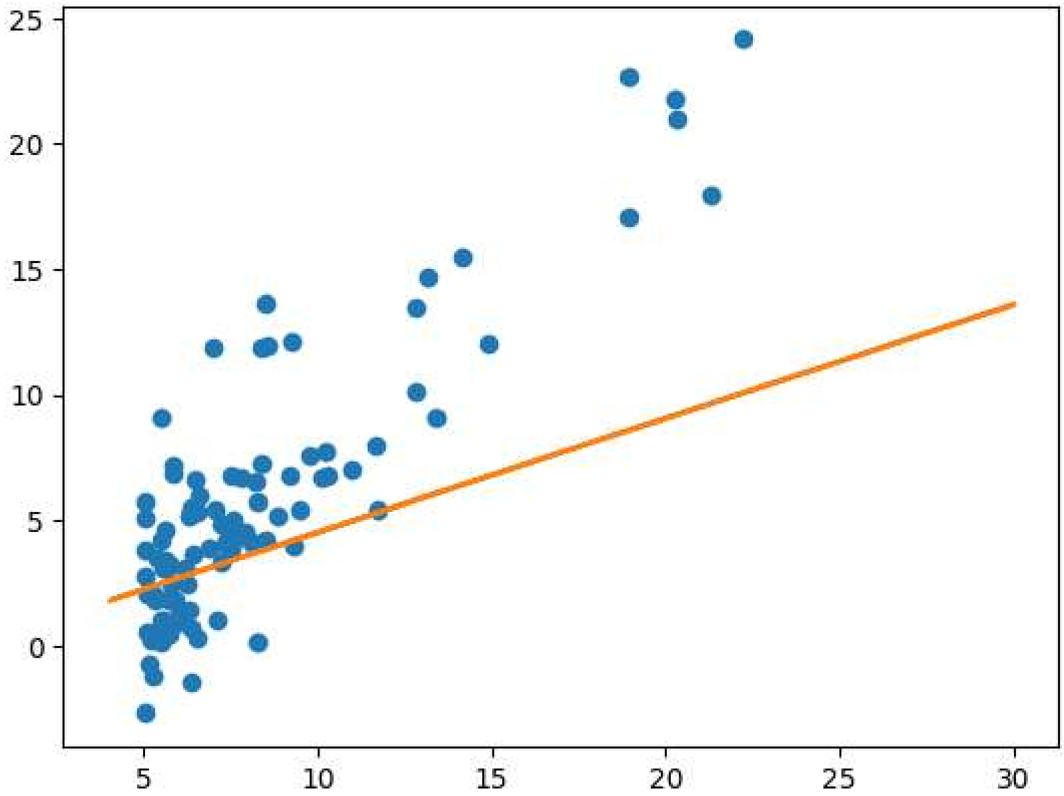

观察图像可以知道，虽然cost在下降，但整体显然还没有到达最小值附近，还需要继续下降才有可能到达，此时cout最小值为10.559618437644504

迭代次数100，下降速度0.001

In [ ]:
```
main(100,0.001)
```

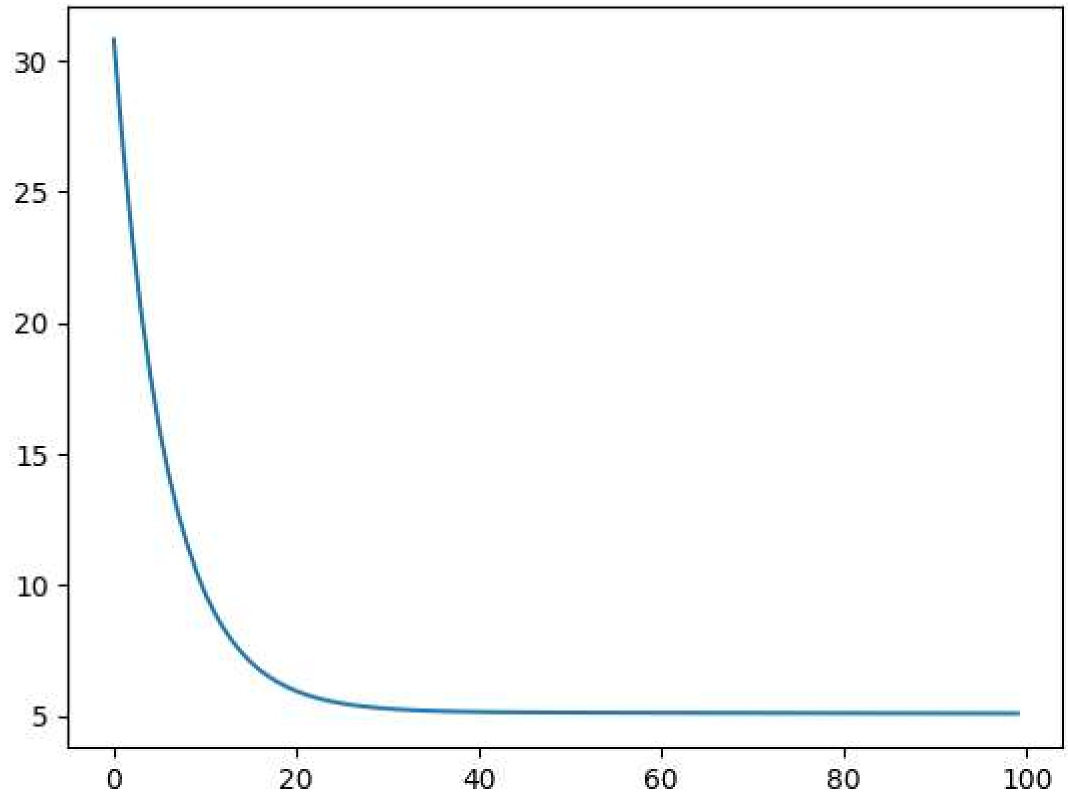

```
[0.00171092 0.79141847]
代价最小为： 5.079117963358392
```

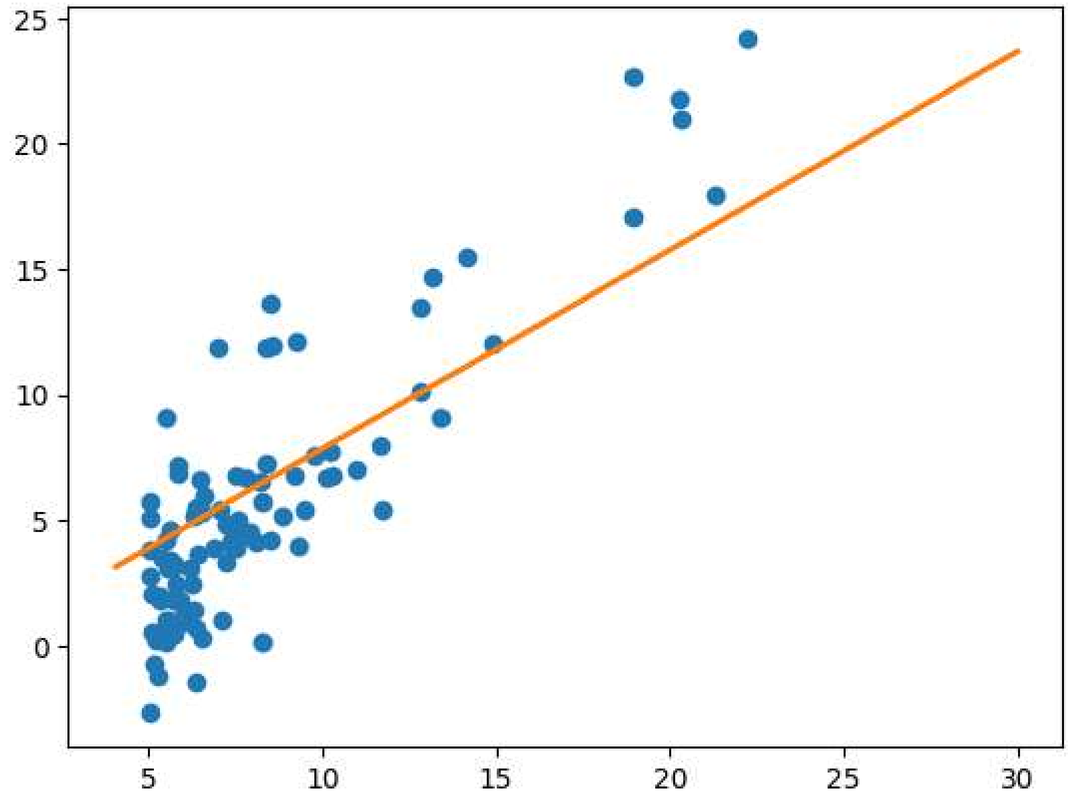

观察图像可以知道，当加大了迭代次数后，下降效果明显比10代强了好多，但是下降到20多代时，发现cost的下降熟读骤然减小，几乎为一条直线 此时的代价最小为5.079117963358392

迭代次数1000，下降速度0.001

In [ ]:
```
main(1000,0.001)
```

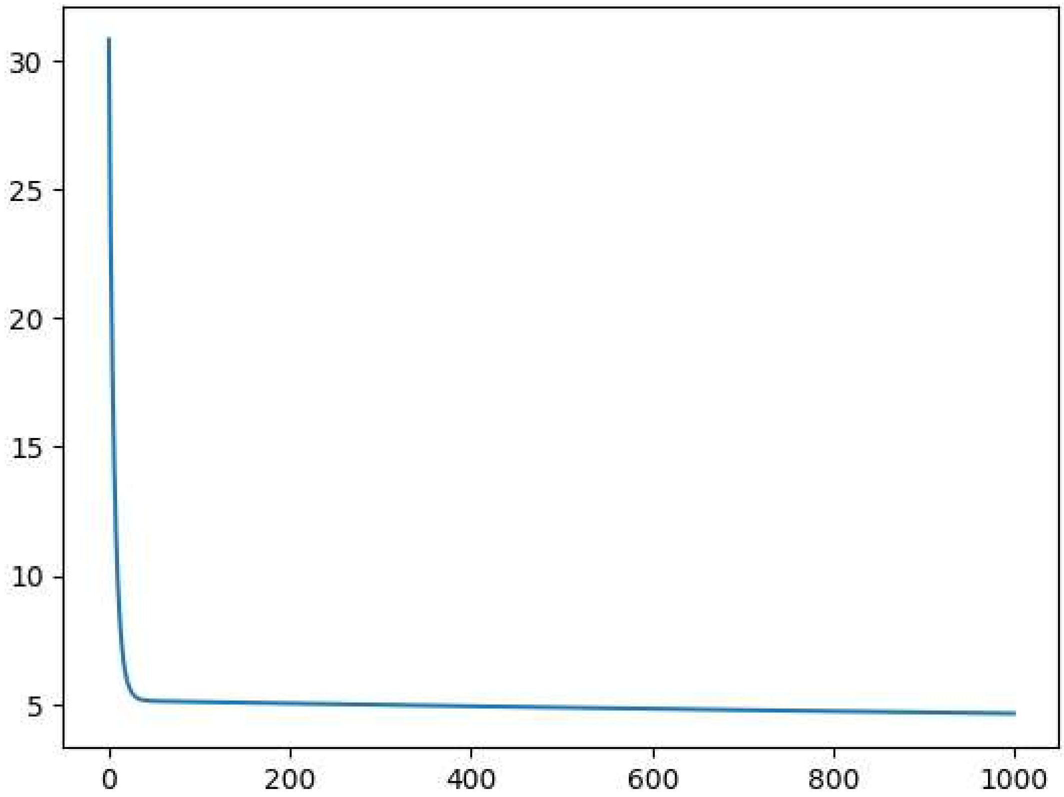


```
[-0.63036147  0.85486704]
代价最小为： 4.629629301471577
```

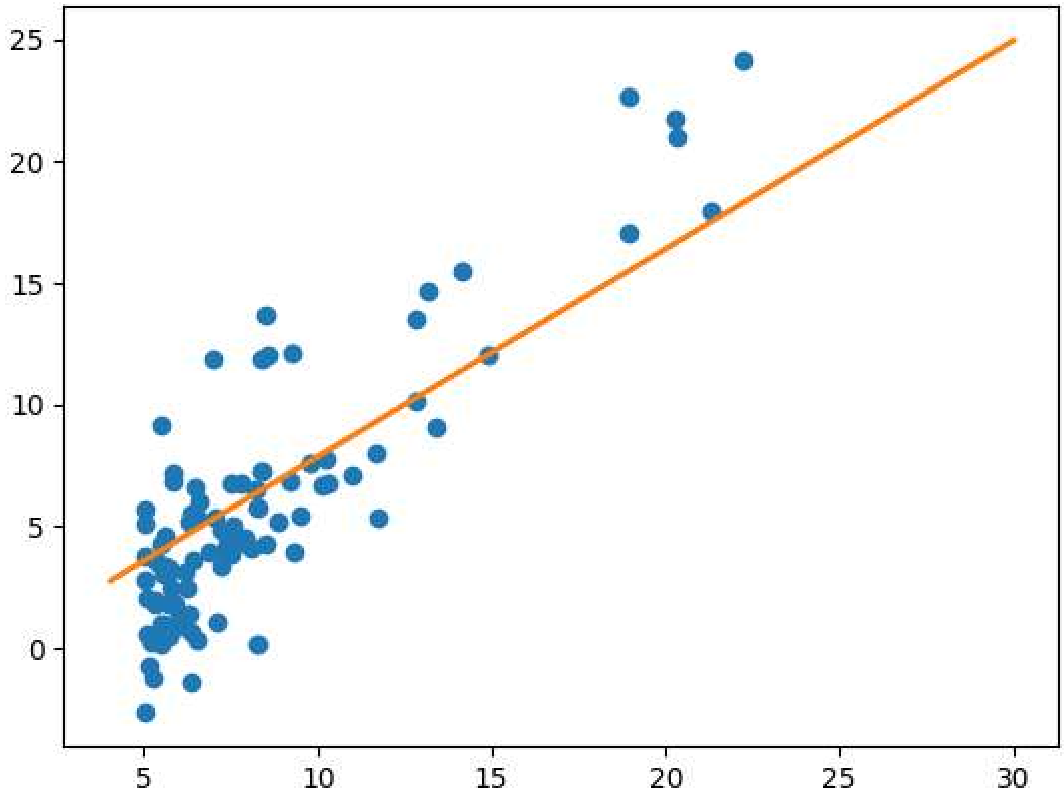

观察图像可以看到，当迭代次数继续增加到1000时，虽然有效果cost依然下降了，但是相比于100次的时候，cost却只减少了0.4左右，代价最小为4.629629301471577
说明随着迭代次数的不断增加，代价下降的越来越缓慢，后期的收益微乎其微，但整体拟合效果还是差了一点

迭代次数100，下降速度0.01

In [ ]:
```
main(100,0.01)
```

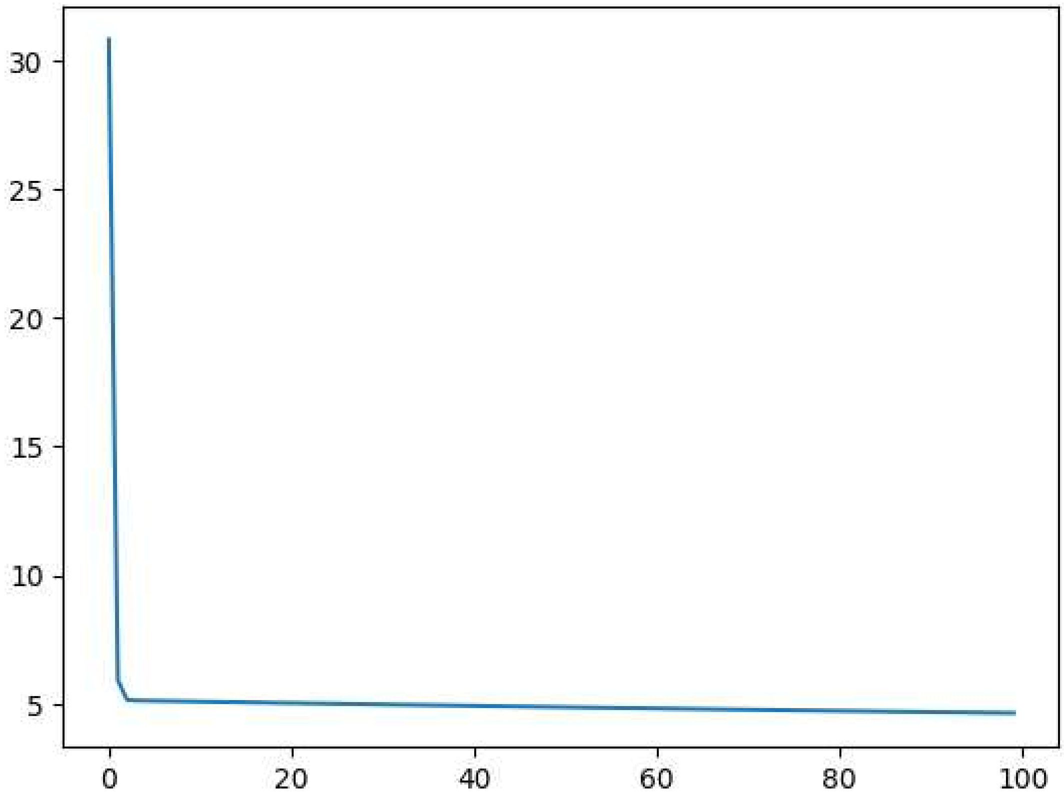


```
[-0.6308877   0.85491974]
代价最小为： 4.633097746092306
```

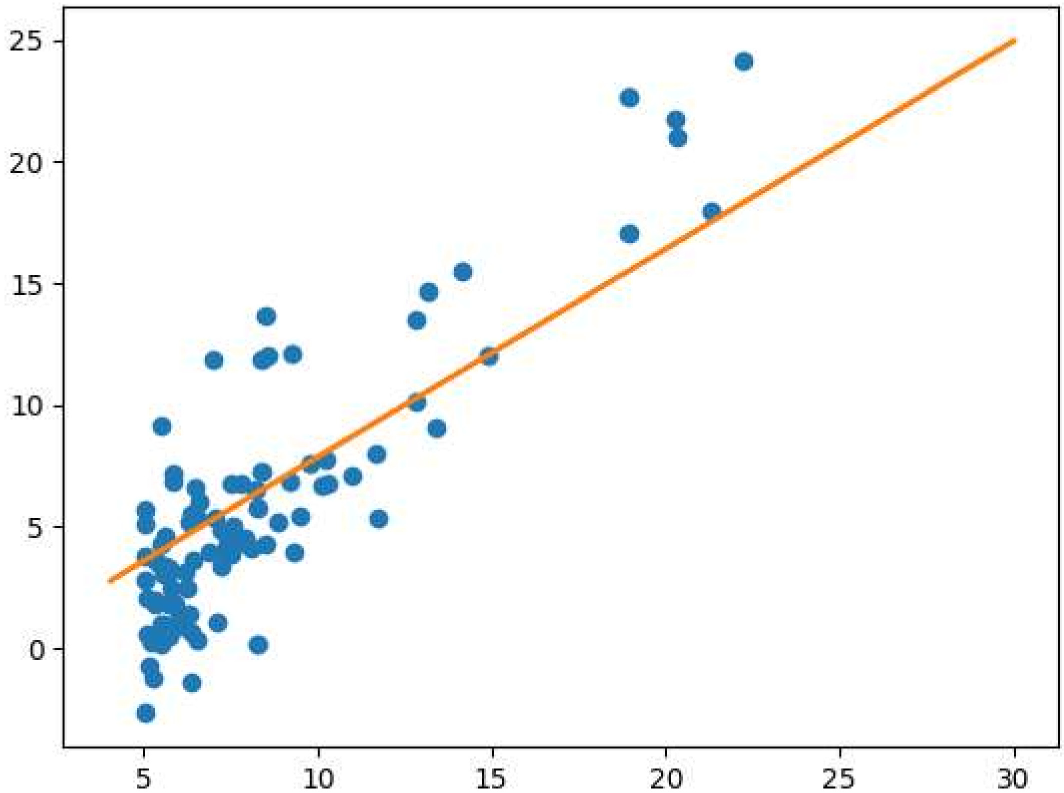

观察图像可以看到，当迭代次数减小到100，但是下降速度怎加到10倍，整体的代价也为4.6左右与1000代的几乎一样，说明当几乎不能靠怎加迭代次数
来继续减小代价的时候，可以增加下降速度来加速下降

迭代次数100，下降速度0.1

In [ ]:
```
main(100,0.1)
```

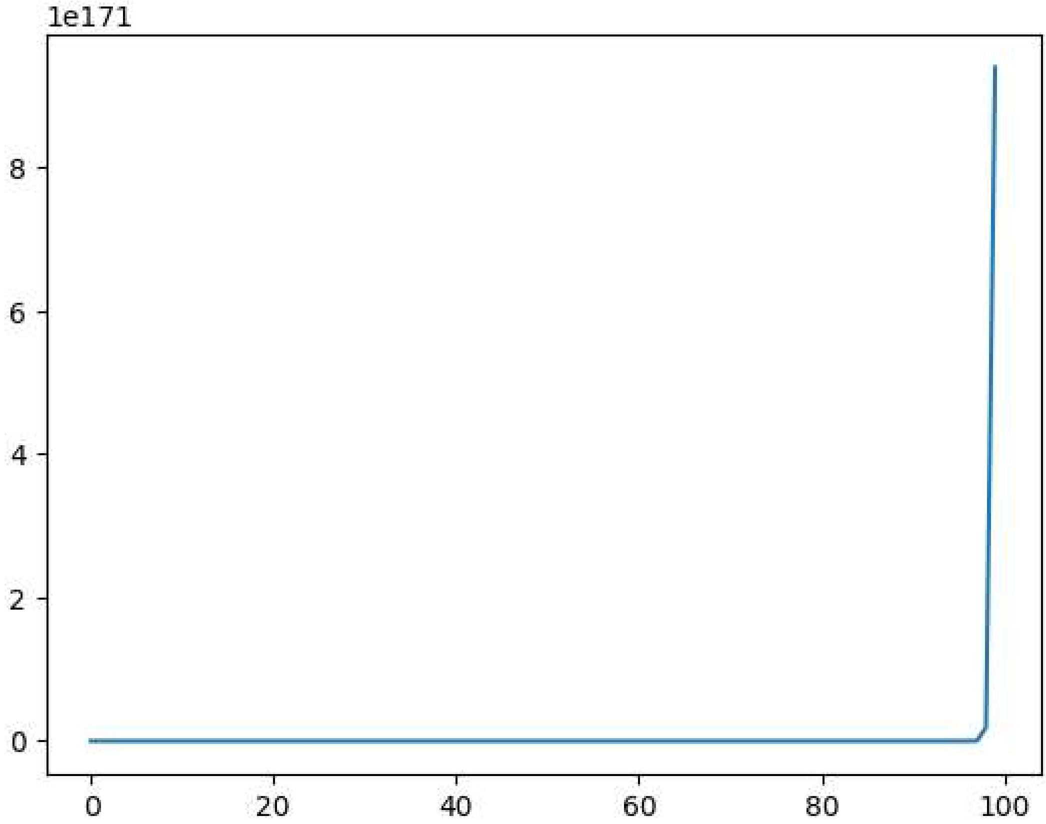


```
[-1.09110472e+85 -1.08938307e+86]
代价最小为： 30.79495785534583
```

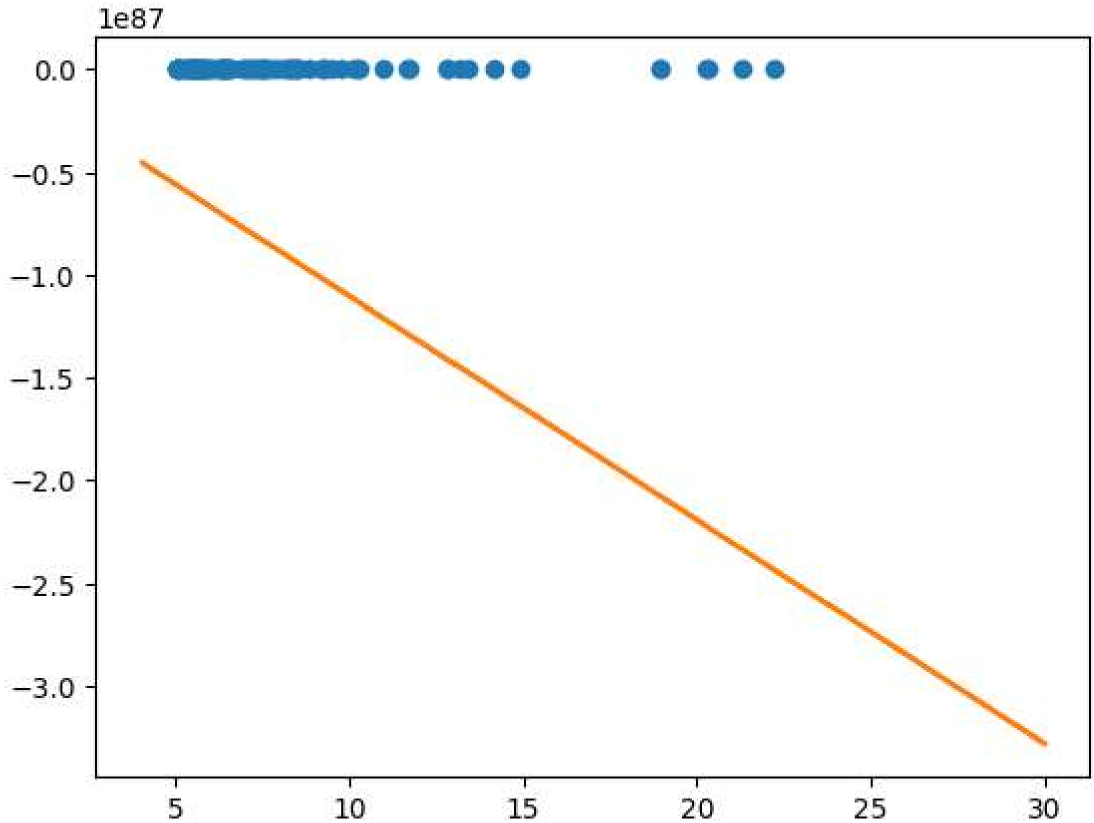

观察图像我们可以看到，cost不仅没有下降反而上升了，这就说明我们的学习速度不能无限制的增加，学习速度过大，就会越过最低点导致cost不收敛

找到规律后不断逼近最大学习速度迭代1000，下降速度0.02

In [ ]:
```
main(1000,0.024)
```

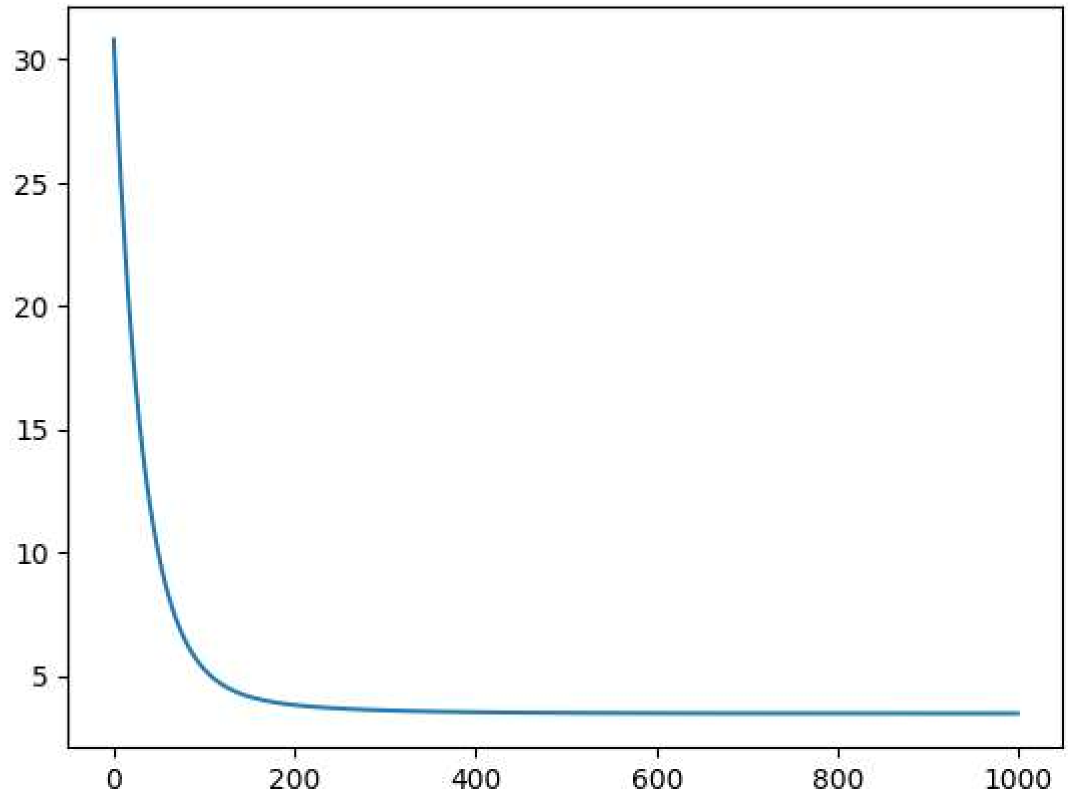

```
[-4.15577958  1.20796589]
代价最小为：  3.459867575064487
```

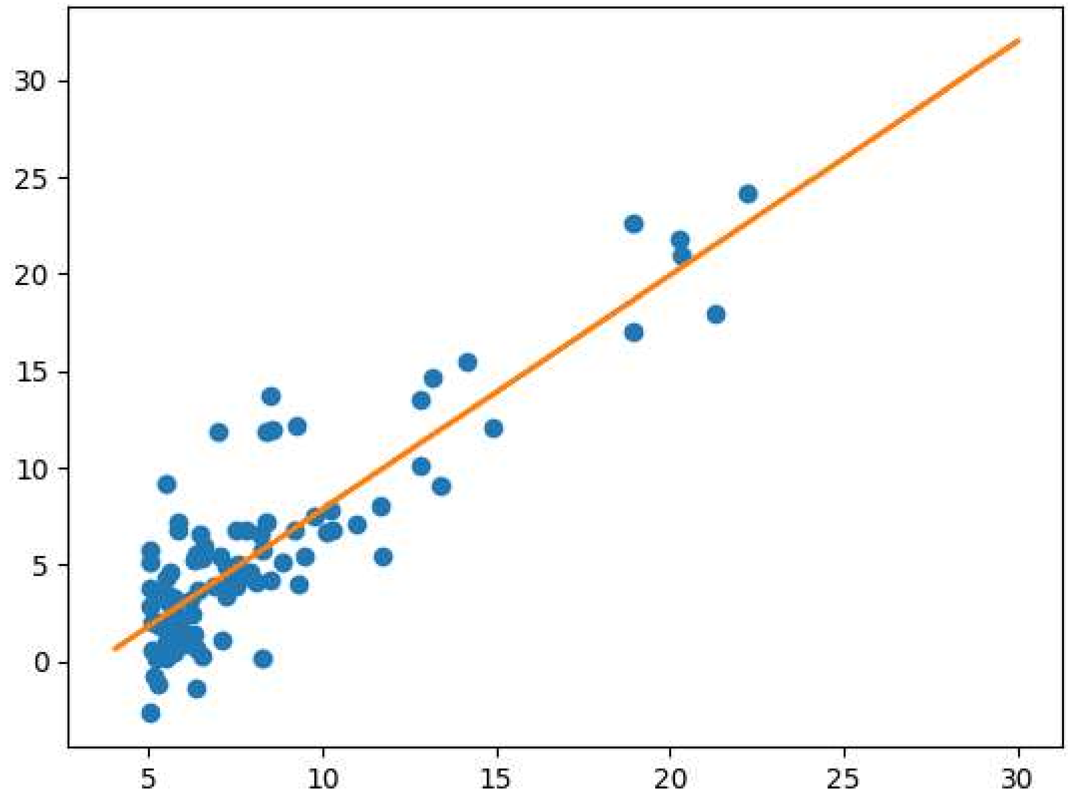

在最后不断地逼近即将发散的点，找到合适的下降速度0.024，然后迭代1000代，最小代价为3.459867575064487 基本拟合散点图